

LAPORAN PRAKTIKUM ARTIFICIAL INTELLIGENCE

Simple Linear Regression & Multiple Linear Regression



Disusun Oleh:

Monica Sitanggang

42324053

DIII Teknologi Informasi

Institut Teknologi Del

Fakultas Vokasi

Praktikum

```
import pandas as pd
df = pd.read_csv('Salary_Data.csv')
print(df.head())
```

✓ 0.9s Python

	YearsExperience	Salary
0	1.1	39343.0
1	1.3	46205.0
2	1.5	37731.0
3	2.0	43525.0
4	2.2	39891.0

Penjelasan:


- Pada cell ini digunakan library Pandas untuk mengolah data. “**import pandas as pd**” digunakan untuk mengimpor Pandas dan memberikan nama singkat pd.
- Kemudian **df = pd.read_csv('Salary_Data.csv')** digunakan untuk membaca file dataset **Salary_Data.csv** dan menyimpannya ke dalam variabel df.
- Selanjutnya **print(df.head())** digunakan untuk menampilkan 5 baris pertama dari dataset. Dataset memiliki dua kolom utama, yaitu:
 1. **YearsExperience** → jumlah tahun pengalaman kerja.
 2. **Salary** → gaji.

```
X = df.iloc[:, :-1].values
y = df.iloc[:, 1].values
```

✓ 0.0s Python

Penjelasan:

- Cell ini digunakan untuk menentukan variabel yang akan digunakan dalam model regresi.
- **X = df.iloc[:, :-1].values** digunakan untuk mengambil semua baris dan semua kolom kecuali kolom terakhir. Pada dataset ini, hasilnya adalah kolom: YearsExperience. Kolom tersebut digunakan sebagai **variabel X atau predictor**.
- Kemudian **y = df.iloc[:, 1].values** digunakan untuk mengambil kolom kedua, yaitu: Salary. Kolom ini menjadi **target atau y** yang akan diprediksi.



Penjelasan:

- Cell ini digunakan untuk melihat hubungan antara pengalaman kerja dan gaji dalam bentuk grafik.
- **plt.scatter(X, y)** digunakan untuk membuat **scatter plot**, yaitu grafik berupa titik-titik.
- Sumbu X menunjukkan **Years Experience** sedangkan sumbu Y menunjukkan **Salary**
- Setiap titik menunjukkan hubungan antara satu nilai pengalaman kerja dengan nilai gaji tertentu.

```
# bagi dataset jadi train dan test 80:20
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 42)
```

Penjelasan:

Cell ini digunakan untuk membagi dataset menjadi dua bagian:

1. Training set → digunakan untuk melatih model.
2. Testing set → digunakan untuk menguji kemampuan model.

Parameter:

- **test_size=0.2** berarti 20% data digunakan sebagai data testing, sedangkan sekitar 80% digunakan sebagai data training.
- **random_state=42** digunakan agar pembagian data tetap sama ketika kode dijalankan kembali.

```
# Fitting Simple Linear Regression to the Training set
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

regressor

✓ 0.0s

LinearRegression ⓘ ⓘ

- ▶ Parameters
- ▶ Fitted attributes

Penjelasan:

Program mengimpor fungsi LinearRegression dari Scikit-Learn.

- **regressor = LinearRegression()** digunakan untuk membuat objek model regresi linear.
- Kemudian **regressor.fit(X_train, y_train)** digunakan untuk melatih model menggunakan data training.

Pada tahap ini model mencoba mencari **garis regresi terbaik** yang menggambarkan hubungan antara pengalaman kerja dan gaji. Secara umum bentuk persamaannya adalah:

$$\hat{y} = a + bx$$

Keterangan:

- $\hat{y}$ = nilai gaji yang diprediksi
- a = intercept
- b = slope/koeffisien
- x = pengalaman kerja

```
a = regressor.intercept_
b = regressor.coef_[0]

print("Estimated model intercept, a:", a)
print("Estimated model slope, b:", b)
print(f"ŷ = {a:.2f} + {b:.2f}x")
```

✓ 0.0s Python

Estimated model intercept, a: 25321.583011776813
 Estimated model slope, b: 9423.815323030976
 ŷ = 25321.58 + 9423.82x

Penjelasan:

Cell ini digunakan untuk mengambil nilai **intercept** dan **slope** dari model yang sudah dilatih.

- **a = regressor.intercept_** digunakan untuk mengambil nilai intercept.

Hasilnya: a = 25321.58

- **b = regressor.coef_[0]** digunakan untuk mengambil nilai koefisien atau slope.

Hasilnya: b = 9423.82

Sehingga persamaan regresinya menjadi:

$$\hat{y} = 25321.58 + 9423.82x$$

```
# Memprediksi hasil pada data uji (Test set) menggunakan model regresi yang telah
y_pred = regressor.predict(X_test)
y_pred
```

✓ 0.0s Python

array([115790.21011287, 71498.27809463, 102596.8686063, 75267.80422384,
 55477.79204548, 60189.69970699])

Penjelasan:

Cell ini digunakan untuk melakukan prediksi terhadap data testing.

- **regressor.predict(X_test)** memasukkan data pengalaman kerja dari X_test ke model yang telah dilatih.
- Hasilnya disimpan ke dalam **y_pred** Variabel tersebut berisi **gaji hasil prediksi model** untuk data testing.


```
# Menghitung nilai R-Square, yang mengukur seberapa baik model regresi linear
# Semakin mendekati 1, semakin baik model

from sklearn.metrics import r2_score
score=r2_score(y_test,y_pred)
score
✓ 0.0s Python
0.9024461774180497
```

Penjelasan:

Cell ini digunakan untuk mengukur seberapa baik model regresi dalam menjelaskan data menggunakan nilai **R-Square (R^2)**.

- **r2_score(y_test, y_pred)** membandingkan:
 1. y_test → nilai sebenarnya.
 2. y_pred → nilai hasil prediksi.
- Nilai R-Square pada praktikum adalah sekitar 0.9024 atau sekitar 90.24%



Penjelasan:

Cell ini digunakan untuk menampilkan hasil regresi pada data training.

- **plt.scatter(X_train, y_train)** menampilkan data training dalam bentuk titik.
- **plt.plot(X_train, regressor.predict(X_train))** membuat garis regresi berdasarkan hasil prediksi model.



Penjelasan:

Cell ini menampilkan data testing dan garis regresi.

- Titik merah menunjukkan data testing sebenarnya, sedangkan garis biru menunjukkan garis regresi yang dihasilkan model.
- Judul grafik:
Salary vs Experience (Test set)
menunjukkan bahwa grafik digunakan untuk melihat hubungan antara pengalaman kerja dan gaji pada data testing.

```
# Multiple Linear Regression
df2 = pd.read_csv('multiple_linear_regression_dataset.csv')
print(df2.head())
```

0.0s Python

	age	experience	income
0	25	1	30450
1	30	3	35670
2	47	2	31580
3	32	5	40130
4	43	10	47830

Penjelasan:

Cell ini membaca dataset kedua yang digunakan untuk Multiple Linear Regression.

Dataset memiliki tiga kolom:

- age
- experience
- income

```
X2 = df2.iloc[:, :-1]
y2 = df2.iloc[:, 2]
```

✓ 0.0s

Penjelasan:

Pada cell ini variabel predictor dan target ditentukan.

- **X2 = df2.iloc[:, :-1]** mengambil semua kolom kecuali kolom terakhir.
Jadi predictor yang digunakan Adalah Age dan experience
- **y2 = df2.iloc[:, 2]** mengambil kolom ketiga, yaitu income
- Jadi:
X1 = age
X2 = experience
y = income

```
# Bagi dataset menjadi train dan test 80:20
X_train2, X_test2, y_train2, y_test2 = train_test_split(X2, y2, test_size = 0.2, random_state=42)
```

✓ 0.0s

Penjelasan:

- Dataset Multiple Linear Regression juga dibagi menjadi:
 1. 80% data training.
 2. 20% data testing.
- **random_state=42** digunakan agar pembagian data konsisten ketika kode dijalankan kembali.

```
regressor = LinearRegression()
regressor.fit(X_train2, y_train2)
```

✓ 0.1s

Penjelasan:

Cell ini membuat model Linear Regression dan melatihnya menggunakan data training.

- Perbedaannya dengan Simple Linear Regression adalah model sekarang menggunakan dua predictor, yaitu:
 1. age
 2. experience
- Model berusaha mencari persamaan:

$$\hat{y} = a + b_1x_1 + b_2x_2$$

```
# Predicting the Test set results
y_pred2 = regressor.predict(X_test2)
print(y_pred2)
```

✓ 0.0s Python

[31093.38107376 31295.49954076 40250.46080162 34897.6958918]

Penjelasan:

Model digunakan untuk memprediksi income berdasarkan data testing.

Hasil prediksi yang diperoleh antara lain:

31093.38

31295.50

40250.46

34897.70

Nilai tersebut merupakan hasil prediksi income dari model untuk data testing.

```
a_ = regressor.intercept_
b1 = regressor.coef_[0]
b2 = regressor.coef_[1]

print("Estimated model intercept, a:", a_)
print("Estimated model slope, b1:", b1)
print("Estimated model slope, b2:", b2)
print(f"ŷ = {a_:.2f} + {b1:.2f}x1 + {b2:.2f}x2")
```

✓ 0.0s Python

Estimated model intercept, a: 31465.056418503944
 Estimated model slope, b1: -101.05923350088776
 Estimated model slope, b2: 2154.8054927746484
 ŷ = 25321.58 -101.06x1 + 2154.81x2

Penjelasan:

Cell ini mengambil nilai intercept dan koefisien dari model.

Hasilnya:

Intercept = 31465.06

b1 = -101.06

b2 = 2154.81

Persamaan regresinya adalah:

$$\hat{y} = 31465.06 - 101.06x_1 + 2154.81x_2$$

Dengan:

1. x_1 = age
2. x_2 = experience

```
# Menghitung nilai R-Square, yang mengukur seberapa baik model regresi linear
# Semakin mendekati 1, semakin baik model

score2=r2_score(y_test2, y_pred2)
score2
0.9387098237077885
```

Penjelasan:

Cell ini digunakan untuk mengevaluasi performa Multiple Linear Regression menggunakan R-Square.

Hasil pada praktikum $R^2 = 0.9387$ atau sekitar **93.87%** Artinya, berdasarkan data testing pada praktikum, sekitar 93,87% variasi nilai income dapat dijelaskan oleh model yang menggunakan age dan experience.

Tugas

1. Simple Linear Regression: prediksi score (y) berdasarkan waktu belajar (X) dari dataset <https://www.kaggle.com/datasets/snmahsa/student-score-suitable-forlinear-regression>

Jawab:

```
df1 = pd.read_csv('rounded_hours_student_scores.csv')
print(df1.head())
```

	Hours	Scores
0	1.1	41
1	1.2	40
2	1.4	38
3	1.5	39
4	1.6	36

Penjelasan:

- Cell ini membaca dataset yang berisi hubungan antara waktu belajar dan nilai siswa.
- Kolom Hours digunakan sebagai predictor dan Scores digunakan sebagai target.


```
X = df1.iloc[:, :-1].values
y = df1.iloc[:, 1].values
```

Penjelasan:

Pada cell ini ditentukan variabel input dan target.

1. X = Hours
2. y = Scores

Artinya model akan mempelajari hubungan antara lama waktu belajar dengan nilai siswa.



Penjelasan:

Cell ini membuat scatter plot untuk melihat hubungan antara waktu belajar dan nilai.

- Sumbu X = Hours
- Sumbu Y = Scores
- Titik merah = data siswa.

Grafik ini digunakan untuk melihat pola data sebelum model dibuat.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Penjelasan:

Data dibagi menjadi:

- 80% → Training
- 20% → Testing

Data training digunakan untuk membuat model, sedangkan data testing digunakan untuk mengevaluasi model.

```
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

Penjelasan:

- Cell ini membuat dan melatih model Simple Linear Regression menggunakan data waktu belajar dan nilai siswa.
- Model mencari garis terbaik untuk memprediksi Scores berdasarkan Hours.

```
a = regressor.intercept_
b = regressor.coef_[0]

print("Estimated model intercept, a:", a)
print("Estimated model slope, b:", b)
print(f"ŷ = {a:.2f} + {b:.2f}x")
```

Estimated model intercept, a: 36.46097067904956
 Estimated model slope, b: 1.8742157088578228
 $\hat{y} = 36.46 + 1.87x$

Penjelasan:

Cell ini mengambil nilai intercept dan slope dari model.

Hasilnya:

1. Intercept = 36.46
2. Slope = 1.87

Sehingga persamaannya:

$$\hat{y} = 36.46 + 1.87x$$

```
y_pred = regressor.predict(X_test)
y_pred
0.0s
array([38.52260796, 39.83455895, 47.70626493, 50.14274535, 41.89619623,
       52.3918042 , 46.95657865, 50.89243164, 41.52135309, 53.14149049,
       50.33016692, 51.45469635])
```

Penjelasan:

- Model digunakan untuk memprediksi nilai siswa berdasarkan data X_test.
- Hasil prediksi disimpan dalam variabel:

y_pred

Hasil tersebut nantinya dibandingkan dengan nilai sebenarnya pada y_test.

```
score=r2_score(y_test, y_pred)
score
0.0s
0.5809502309078736
```

Penjelasan:

- Cell ini digunakan untuk mengetahui seberapa baik model memprediksi nilai siswa.
- Nilai R-Square membandingkan nilai sebenarnya dengan nilai hasil prediksi.
- Semakin mendekati 1, semakin besar variasi target yang dapat dijelaskan oleh model.

2. Multiple Linear Regression: prediksi sales (y) berdasarkan data marketing (x) di youtube, facebook, newspaper, dari dataset <https://www.kaggle.com/datasets/fayejavad/marketing-linear-multiple-regression>

Jawab:

```
df2 = pd.read_csv('Marketing_Data.csv')
print(df2.head())
0.0s
youtube facebook newspaper sales
0 84.72 19.20 48.96 12.60
1 351.48 33.96 51.84 25.68
2 135.48 20.88 46.32 14.28
3 116.64 1.80 36.00 11.52
4 318.72 24.00 0.36 20.88
```

Penjelasan:

- Cell ini membaca dataset marketing.
- Dataset memiliki empat kolom:
 1. youtube
 2. facebook
 3. newspaper
 4. sales
- Variabel yang seharusnya menjadi predictor adalah:
 1. YouTube

2. Facebook
 3. Newspaper
- dan targetnya adalah Sales

```
X2 = df2.iloc[:, :-1]
y2 = df2['sales']
```

✓ 0.0s Python

Penjelasan:

- Cell ini digunakan untuk menentukan **variabel predictor (X)** dan **variabel target (y)**.
- **X2 = df2.iloc[:, :-1]** digunakan untuk mengambil semua kolom kecuali kolom terakhir. Pada dataset ini, kolom yang digunakan sebagai predictor adalah:
 1. youtube
 2. facebook
 3. newspaper
- Jadi:
X2 = YouTube + Facebook + Newspaper
- **y2 = df2['sales']** digunakan untuk mengambil kolom sales sebagai target yang akan diprediksi.

```
X_train2, X_test2, y_train2, y_test2 = train_test_split(X2, y2, test_size=0.2, random_state=42)
```

✓ 0.0s Python

Penjelasan:

- Dataset marketing dibagi menjadi:
80% → Data training
20% → Data testing
- Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk melihat hasil prediksi.

```
regressor = LinearRegression()
regressor.fit(X_train2, y_train2)
```

✓ 0.0s Python

> LinearRegression ⓘ ⓘ

Penjelasan:

Cell ini membuat dan melatih model Multiple Linear Regression menggunakan tiga predictor:

1. YouTube
2. Facebook
3. Newspaper

```

y_pred2 = regressor.predict(X_test2)
print(y_pred2)
✓ 0.0s Python
[12.98143963 25.0567515 18.23740714 20.62856013 11.58829542 8.56498386
13.34769213 23.17303975 12.02633774 24.95658385 10.22642185 13.42592269
13.98390345 11.02921411 20.75850022 26.45365807 28.93272026 21.7591148
21.250927 24.16369214 20.67745028 9.84089667 19.43433157 18.23654615
14.28836092 26.10738797 20.88069217 10.57749746 12.21748717 23.14056427
7.00528355 8.46444339 16.59917838 21.84022174 18.1370266 ]

```

Penjelasan:

- Model digunakan untuk melakukan prediksi terhadap data testing.
- Hasil prediksi ditampilkan menggunakan print().

```

a = regressor.intercept_
b1 = regressor.coef_[0]
b2 = regressor.coef_[1]
b3 = regressor.coef_[2]
print("Estimated model intercept, a:", a_)
print("Estimated model slope, b1:", b1)
print("Estimated model slope, b2:", b2)
print("Estimated model slope, b3:", b3)
print(f"ŷ = {a_:.2f} + {b1:.2f}x1 + {b2:.2f}x2 + {b3:.2f}x3")
✓ 0.0s Python
Estimated model intercept, a: 0.0
Estimated model slope, b1: 8.887783143427763e-18
Estimated model slope, b2: 1.0
Estimated model slope, b3: 0.0
ŷ = 0.00 + 0.00x1 + 1.00x2 + 0.00x3

```

Penjelasan:

- Cell ini digunakan untuk mengambil:
 1. $a_{_}$ → intercept.
 2. $b1$ → koefisien YouTube.
 3. $b2$ → koefisien Facebook.
 4. $b3$ → koefisien Newspaper.
- Hasil yang terdapat pada notebook:
Intercept = 0.00
 $b1 = 0.00$
 $b2 = 1.00$
 $b3 = 0.00$
- Sehingga persamaan yang dihasilkan:

$$\hat{y} = a + b1(\text{YouTube}) + b2(\text{Facebook}) + b3(\text{Newspaper})$$

```

score2=r2_score(y_test2,y_pred2)
score2
✓ 0.0s Python
0.872863085701216

```

Penjelasan:

- Cell ini digunakan untuk menghitung nilai R-Square dari model Multiple Linear Regression.
- Nilai tersebut digunakan untuk mengetahui seberapa baik model memprediksi target.
- Nilai R-Square menunjukkan seberapa besar variasi nilai sales yang dapat dijelaskan oleh model berdasarkan tiga predictor yang digunakan, yaitu YouTube, Facebook, dan Newspaper